서송병원 예측 결과 보고서

LAVAR 시드 안정성, 블렌드 강건성, 앙상블 구간 결과

LAVAR Health-Economic Forecasting Study

2026년 6월

Abstract

본 보고서는 Seosong 복제 워크플로에서 산출한 서송병원 예측 결과를 요약한다. 평가는 2020-12-14부터 2025-12-31까지의 일별 환자 특성과 처방 타깃을 사용했으며, 관측치는 1,844일, 환자 측 공변량은 38개, 처방 타깃은 3,126개이다. 다섯 개 난수 시드와 시드별 79개 rolling fold 기준으로 보면, S11 latent-16 설정은 S04 GRU 설정보다 평균 MSE가 낮았지만 시드 간 변동성과 tail risk가 더 컸다. 고정 블렌드 $0.55\times$S11 $+0.45\times$S04는 pure S11 대비 평균 MSE를 0.0596, 즉 3.17% 낮췄다. 다만 p95 fold MSE가 pure S11보다 악화되어 현재 promotion rule은 충족하지 못했다.

1 데이터와 평가 설정

본 보고서는 Seosong seed stability, blend robustness, ensemble workflow의 결과 산출물을 근거로 작성했다. 기본 데이터 파일은 다음과 같다.

- `data_patient.parquet`: 1,844행, 38열.
- `data_prescription.parquet`: 1,844행, 3,126열.
- 기간: 2020-12-14부터 2025-12-31까지.

각 시나리오는 다섯 개 시드 $\{42, 123, 456, 789, 1024\}$로 평가했다. Rolling evaluation은 14일 forecast horizon, 14일 fold step, 90일 retraining cadence, quality trigger 활성화, run별 79개 fold 설정을 사용했다.

2 모델 시나리오

Seosong workflow는 두 개의 base scenario와 하나의 고정 블렌드를 비교한다.

- **S04_GRU_H32_L1**: GRU temporal decoder baseline.
- **S11_LATENT16**: latent dimension 16 설정.
- **Blend w=0.55**: $0.55\times$S11 $+0.45\times$S04이며, 예측값은 음수가 되지 않도록 clipping했다.

앙상블 구간 산출물은 다섯 개 seeded blend prediction을 사용해 경험적 95% prediction interval을 계산한다.

3 시드 안정성 결과

Table 1는 `seed_stability_summary.csv`의 시드 안정성 요약이다. S11은 평균 MSE와 MAE가 더 낮지만, 평균 MSE의 coefficient of variation이 S04보다 약 여섯 배 커서 시드 반응이 덜 안정적이다.

Table 1: Base scenario별 시드 안정성.

Scenario	Seeds	Mean MSE	SD MSE	CV MSE	Mean MAE	p95 Fold MSE
S04 GRU H32 L1	5	2.0234	0.0540	0.0267	0.2712	4.6293
S11 LATENT16	5	1.8810	0.2986	0.1587	0.2616	4.4179

S11의 평균 MSE는 S04보다 0.1424 낮으며, 이는 S04 대비 7.04% 감소에 해당한다. 그러나 S11의 최악 시드 기준 maximum fold MSE는 20.8928까지 상승한 반면, S04의 해당 값은 13.7482였다.

4 블렌드와 앙상블 결과

Table 2은 고정 블렌드를 pure S04 및 pure S11과 비교한 전체 앙상블 요약이다. 블렌드는 평균 MSE와 평균 maximum-fold MSE 기준으로 가장 좋았지만, p95 fold MSE 기준으로는 pure S11이 가장 좋았다.

Table 2: 전체 앙상블 비교.

Label	Seeds	Mean MSE	SD MSE	Mean MAE	p95 Fold MSE
Blend w=0.55	5	1.8214	0.1641	0.2615	4.4676
Pure S04	5	2.0210	0.0520	0.2708	4.6053
Pure S11	5	1.8810	0.2986	0.2616	4.4179

Pure S11과 비교하면, 고정 블렌드는 평균 MSE를 0.0596(-3.17%) 낮추고 평균 MSE의 시드 간 표준편차를 0.2986에서 0.1641로 줄였다. Pure S04와 비교하면, 블렌드는 평균 MSE를 0.1995(-9.87%) 낮췄다. 대신 tail 성능에는 tradeoff가 있다. 블렌드 p95 fold MSE는 4.4676으로, pure S11보다 0.0497 높다.

5 강건성 판정

Fixed-weight robustness decision table에 따르면 $w = 0.50$과 $w = 0.55$는 모두 다섯 개 시드 중 세 개 시드에서 mean MSE 기준으로 승리했고, 두 개 시드에서 p95 fold MSE 기준으로 승리했으며, 두 기준을 동시에 만족한 시드는 두 개뿐이었다. 따라서 두 weight 모두 `promote_blend_rule=False`로 판정됐다.

Table 3: 블렌드 promotion decision.

w	Seeds	Mean-MSE Wins	p95 Wins	Both Wins	Mean ΔMSE
0.50	5	3	2	2	-0.0538
0.55	5	3	2	2	-0.0596

즉, 블렌드는 평균 오차를 줄이고 variance를 안정화하는 데 유용하지만, tail-fold robustness를 운영 기준으로 삼는다면 pure S11을 대체하는 기본 운영 규칙으로 승격하기에는 아직 충분하지 않다.

6 구간 예측 산출물

최종 앙상블 workflow는 seeded blend prediction에서 약품별 경험적 95% 구간을 생성한다. 해당 산출물은 `ensemble_ci_per_drug.csv`이다. Figure 1는 선택된 약품 타깃에 대해 실제값, 앙상블 예측값, 경험적 구간을 함께 표시한다.

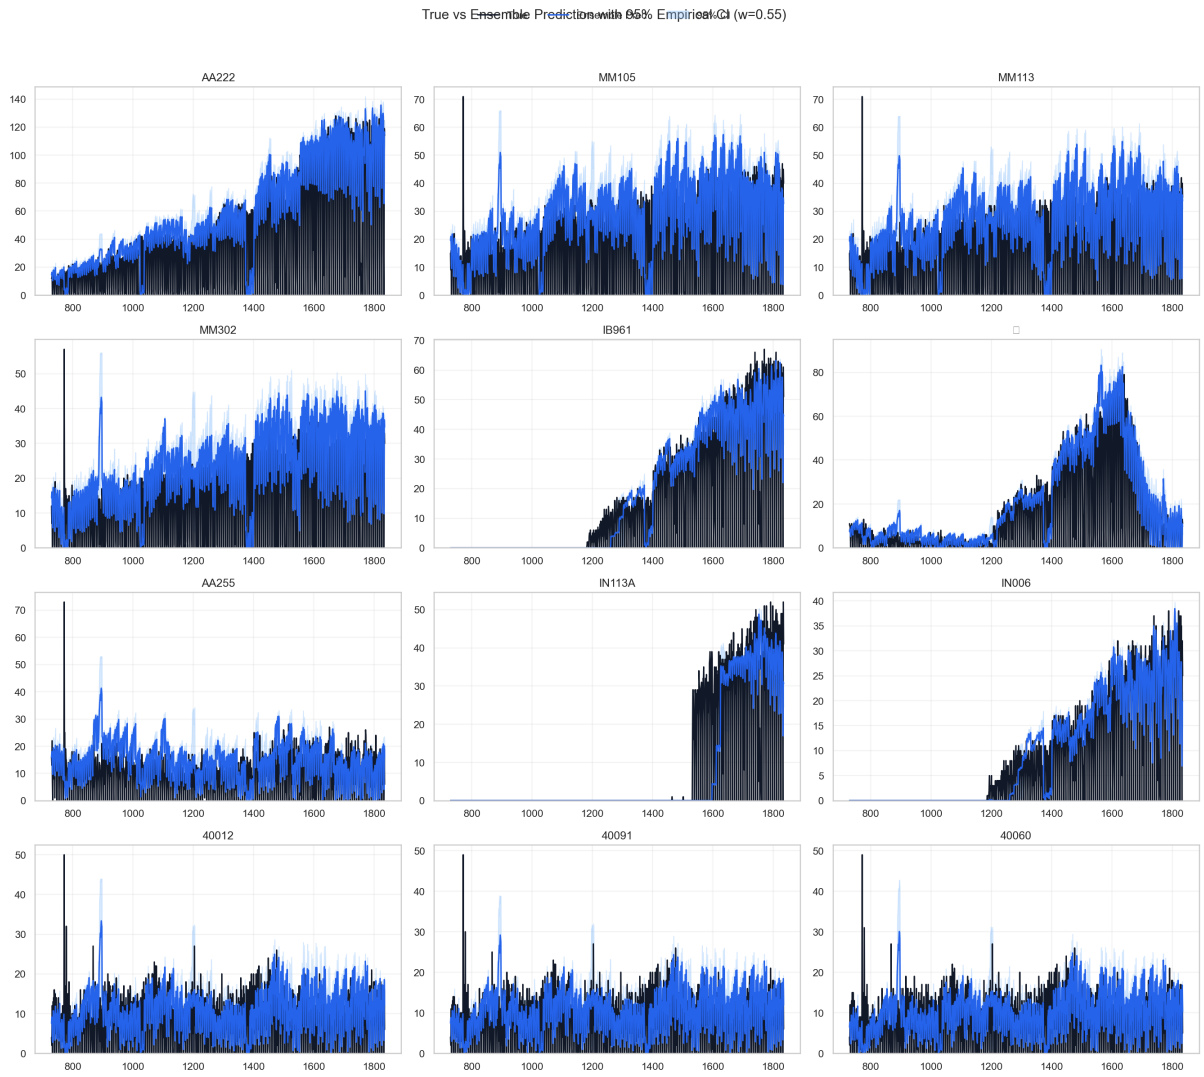


Figure 1: Seosong 앙상블 실제값, 예측값, 경험적 95% 구간.

7 결론

서송병원 결과에서 S11 LATENT16은 평균 오차 기준으로 더 강한 단일 모델이고, S04는 시드 안정성이 더 높다. $w = 0.55$ 블렌드는 가장 낮은 평균 MSE를 보이고 S11의 시드 분산을 상당히 줄이지만, pure S11 대비 p95 fold MSE를 악화시키므로 현재 promotion rule은 통과하지 못한다. 권장 보고 관점은 다음과 같다.

- S11을 primary single-model benchmark로 사용한다.
- $w = 0.55$ 블렌드는 variance-stabilized sensitivity analysis와 interval production model로 유지한다.
- Tail-fold robustness가 개선되기 전까지 블렌드를 default model로 승격하지 않는다.